





Homomorphic Encryption and Federated Learning based Privacy-Preserving CNN Training: COVID-19 Detection Use-Case

Roteiro




- Introdução
- Criptografia Homomórfica
 - Brakerski-Fan-Vercauteren (BFV)
- Proposta
- Modelo do sistema
 - Esquema do método proposto
 - Modelo CNN
 - Cliente
 - Servidor de agregação
 - Cliente - Descriptografia
- Resultados
 - Configuração dos experimentos
 - Tempo de execução
 - Desempenho do modelo
- Conclusão


Introdução



- O aprendizado federado (FL) permite que múltiplos dispositivos treinem um modelo conjunto sem compartilhar dados locais.
- Informações sensíveis, como informações médicas, não podem ser acessadas por terceiros.
- Problemas de privacidade surgem devido ao vazamento de gradientes, que podem revelar informações confidenciais [Deep Leakage Gradients, Zhu et al.].
- Algumas abordagens podem ser usadas para mitigar esse problema.
- Criptografia Homomorfica.




Criptografia Homomórfica




- Técnica criptográfica que permite realizar cálculos diretamente sobre dados criptografados sem necessidade de decriptá-los.
- Os resultados permanecem criptografados e podem ser descriptografados somente pela parte autorizada, garantindo a privacidade dos dados.
- **Tipos Principais:**
 - **Criptografia Parcialmente Homomórfica (PHE):** Suporta operações limitadas (adição ou multiplicação).
 - **Criptografia Homomórfica Leve (SHE):** Suporta um número fixo de operações aritméticas limitadas.
 - **Criptografia Homomórfica Completa (FHE):** Permite qualquer operação aritmética em dados criptografados, mas é computacionalmente mais intensa.

Brakerski-Fan-Vercauteren (BFV)




- Esquema levemente homomórfico.
- Criptografa polinômios ao invés de bits.
- Sua segurança é baseada na dificuldade do problema SIS (Short integer solution problem)
- Criptografia em números inteiros.
- Garante precisão exata em operações aritméticas.

Proposta



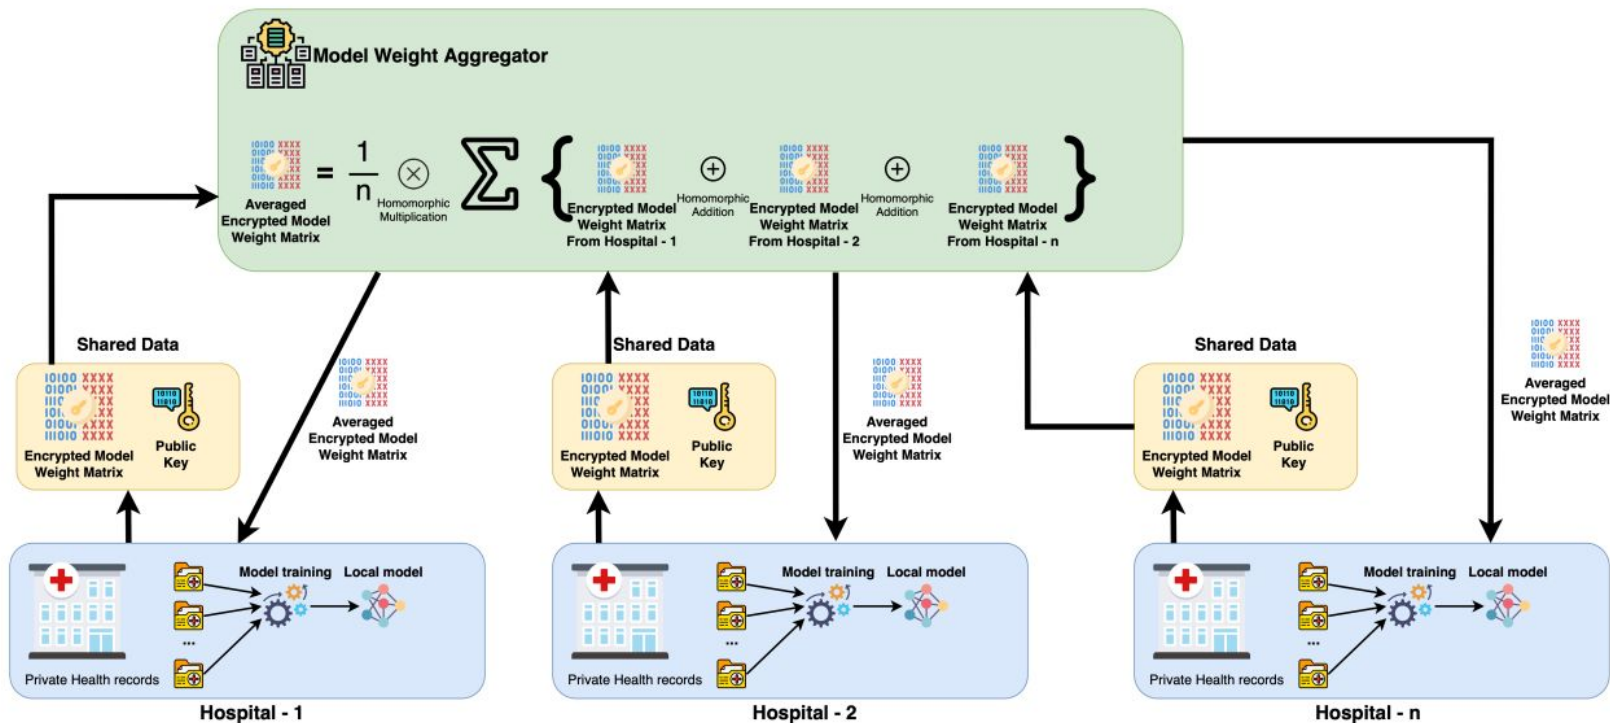

- Dados médicos de um paciente devem ser mantidos privados.
 - Arquitetura FL é focada em privacidade, mas possui falhas.
 - Criptografia é usada para comunicação segura na presença de um adversário (e.g., servidor curioso, mas honesto, servidor atacante, etc.)
 - Criptografia homomórfica permite operações aritméticas em dados criptografados.
-
- **Objetivo:** Desenvolver um modelo de CNN que preserve a privacidade para detecção de COVID-19.
 - **Proposta:** Usar aprendizado federado com criptografia homomórfica para agregar pesos de modelos de forma segura.

Modelo do sistema





- Problema bizantino.
 - Servidor honesto, mas curioso; servidor adversarial.
- Modelo CNN DL.
- Servidor de agregação FedAvg
- Esquema de criptografia homomórfica BFV.
- Somewhat Homomorphic Encryption.


Esquema do método proposto.



Modelo CNN



Cliente




Algorithm 1 Model training in each client

Require: The dataset at client c : $\mathcal{D}_c = \{(\mathbf{x}, y) | \mathbf{x} \in \mathbb{R}^m, y \in \mathbb{R}\}_{i=0}^m$, public

key: Key_{pub}

- 1: $X_{train}, X_{test}, Y_{train}, Y_{test} \leftarrow train_test_split(\mathcal{D})$
 - 2: $h \leftarrow global_model$
 - 3: $h.fit(X_{train}, Y_{train})$
 - 4: $W \leftarrow \emptyset$ // Create an empty matrix for the encrypted layer weights
 - 5: **for each** $layer \in h$ **do**
 - 6: $\llbracket W \rrbracket \leftarrow encrypt_fractional(layer.weights, key_{pub})$ // Encrypt the layer weights ($layer.weights \in \mathbb{R}^m$) with public key.
 - 7: **end for**
 - 8: **Return** $\llbracket W \rrbracket$ // The encrypted weight matrix
-

Servidor de agregação



Algorithm 2 Model aggregation at the server

Require: public key: Key_{pub} , the number of clients: c , client model

weights: $H = \{\llbracket W \rrbracket_i\}_{i=0}^c$

1: $\llbracket W \rrbracket_{aggr} \leftarrow \emptyset$

2: **for each** $h \in H$ **do**

3: **for each** $\llbracket row \rrbracket \in h$ **do**

4: $\llbracket W \rrbracket_{aggr} \leftarrow \llbracket W \rrbracket_{aggr} \oplus \llbracket row \rrbracket$ // Homomorphic addition

5: **end for**

6: **end for**


7: **for each** $\llbracket row \rrbracket \in \llbracket W \rrbracket_{aggr}$ **do**

8: $\llbracket row \rrbracket \leftarrow \llbracket row \rrbracket \otimes c^{-1}$ // Homomorphic multiplication.

9: **end for**

10: **Return** $\llbracket W \rrbracket_{aggr}$ // Return the aggregated weight matrix in the encrypted domain

Cliente - Descriptografia




Algorithm 3 Client decryption

Require: private key: Key_{priv} , encrypted aggregated weights: $\llbracket W \rrbracket_{aggr}$



- 1: $h \leftarrow global_model$
 - 2: **for each** $layer \in h$ **do**
 - 3: $\llbracket row \rrbracket \leftarrow \llbracket W \rrbracket_{aggr}(layer)$ // Get the corresponding row for layer
 - 4: $layer \leftarrow decrypt_fractional(\llbracket row \rrbracket, key_{priv})$ // Decrypt the row and update the layer weights
 - 5: **end for**
 - 6: $h.save_model(global_model)$ // Save the aggregated model as $global_model$ at client.
-

Resultados - Configuração dos experimentos




- Python com Keras/TensorFlow
- Microsoft SEAL.
- Data set: Raio-x de testes de Covid-19, com mil exemplos (80/20 treino/teste).
- Modelo:
 - Convolutacional: 32x32x32x64x512x512
 - Fully connected: 128x64x2
- Foi elaborado um sistema de N clientes com um grau polinomial Q .
 - ($n \in N, N = \{2,3,5,7\}$)
 - ($q \in Q, Q = \{128,192\}$)

Resultados - Tempo de execução




Resultados - Desempenho do modelo



Clients	Accuracy			F1			Precision			Recall		
	128	192	Plain	128	192	Plain	128	192	Plain	128	192	Plain
2	0.8375	0.8400	0.8450	0.834132	0.837030	0.842123	0.867337	0.866735	0.872128	0.8375	0.8400	0.8450
3	0.8400	0.8400	0.8375	0.838040	0.836801	0.834369	0.857293	0.868924	0.865112	0.8400	0.8400	0.8375
5	0.8300	0.8325	0.8350	0.827078	0.829732	0.832164	0.853925	0.855624	0.859288	0.8300	0.8325	0.8350
7	0.8525	0.8450	0.8275	0.850776	0.842540	0.824649	0.869584	0.868000	0.850277	0.8525	0.8450	0.8275

Conclusão



- **Relevância:** Ferramenta valiosa para a privacidade de dados médicos em aprendizado de máquina.
- **Contribuição:** Demonstra a viabilidade de aprendizado federado e criptografia homomórfica combinados para proteção de dados.
- **Perspectivas Futuras:** Explorar a aplicabilidade em outros cenários, outras técnicas de criptografia homomórfica (CKKS) e otimizar o tempo de execução.