





Ataques em redes FL veiculares

Yuri Dimitre Dias de Faria




Contextualização do problema




- **Utility-Centric Threats:** foca em ataques adversárias que comprometem os dados e os modelos, infectando os mesmos.
- **Privacy-Centric Threats:** são ataques focados em exposição de dados, risco de vazamento de informações sensíveis e comprometimento da confiança do sistema FL.

Contextualização do problema




- Data poisoning
 - Label flipping
 - Poisoning samples
 - Out-of-distribution
- Model poisoning
 - Random weights generation
 - Optimization methods
 - Information leakage



Rodríguez-Barroso, Nuria, Daniel Jimenez L'opez, M. Victoria Luz'on, Francisco Herrera and Eugenio Martínez-Cámara.
"Survey on Federated Learning Threats: concepts, taxonomy on attacks and defences, experimental study and challenges."
ArXiv abs/2201.08135 (2022)

Contextualização do problema



- Ataques de Acesso remoto:

- Envio de dados Falsos *
- Bloqueio de Sinais
- Coleta de Dados Confidenciais

- Ataques de Acesso Físico

- Reprogramação de ECU
- Falsificação de Dados de Entrada


- Modelos de Ataque Específicos:

- Dispositivos Maliciosos OBD
- Ataques CAN
- Ataques LiDAR, Radar, GPS, Câmera *
- Ataques de Rede

- LiDAR: Light detection and ranging
- ECU: Electronic Control Unit
- OBD: On Board Diagnostic
- CAN: Control Area Network


* : foco da pesquisa

Contextualização do problema



- Problemas em aberto em FL e CAVs.
 - **Explicabilidade e interpretabilidade em ataques FL:** Explicar como uma rede FL opera pode ser essencial para prevenir certos tipos de ataques, como data poisoning. Além disso, explicabilidade é essencial em certas áreas, como a área da saúde.
 - **Robustez contra Sybil attacks:** Sybil attacks envolve a criação de múltiplas identidades falsas com a intenção de controlar o sistema FL.
 - **Catastrophic forgetting:** CAVs não conseguem armazenar todas as informações do usuário, e precisa de treinamento constante. Com isso, CAVs ficam sujeitos a ataques constantemente.
 - **Trade-off in defences:** A maioria das defesas, é observado que existe um trade-off entre impedir um certo tipo de ataque e executar a tarefa proposta.


Trabalhos relacionados



- **Objetivo:** Investigar a resiliência a falhas bizantinas em implementações distribuídas de descida do gradiente estocástico. Como um SGD distribuído pode ter tolerância um número f de processos bizantinos entre n workers.
- **Solução:** Algoritmo de agregação Krum. O Krum seleciona o vetor de atualização que minimiza a soma das distâncias quadradas para seus $n - f$ vetores vizinhos mais próximos.
- **Limitações:**
 - Custo computacional: Complexidade $O(n^2 * d)$, onde d é a dimensão do vetor de parâmetros
 - Desempenho com mini-batch pequeno: Krum pode desacelerar o aprendizado quando o mini-batch for muito pequeno.
 - Condições necessárias para convergência: Precisão do estimador de gradiente.

Peva Blanchard, El Mahdi El Mhamdi, Rachid Guerraoui, and Julien Stainer. 2017. Machine learning with adversaries: byzantine tolerant gradient descent. In Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS'17). Curran Associates Inc., Red Hook, NY, USA, 118–128.


Trabalhos relacionados



- **Objetivo:** Desenvolver defesa contra ataques de envenenamento que já poluíram o global model.
- **Solução:** White Blood Cell for FL. Defesa baseada no cliente que visa identificar o espaço de parâmetros onde reside o efeito de ataque de longa duração e perturbar esse espaço durante o treinamento local.
- **Limitações:**
 - Ataques extremamente fortes: Falha em garantir a robustez quando os ataques são extremamente fortes.
 - Configuração Não-IID: Não-IID pode levar a uma matriz esparsa, que é provável de ter um núcleo de uma dimensão maior, dificultando a mitigação do efeito do ataque.
 - Perda de precisão benigna: Pode resultar em uma queda de 15% de precisão em configurações Não-IID

Sun, J., Li, A., DiValentin, L., Hassanzadeh, A., Chen, Y., & Li, H. (2021). FL-WBC: Enhancing Robustness against Model Poisoning Attacks in Federated Learning from a Client Perspective. In *Advances in Neural Information Processing Systems* (pp. 12613–12624). Curran Associates, Inc..


Trabalhos relacionados



- **Objetivo:** Desenvolver uma defesa contra backdoor em FL usando uma learning rate robusta.
- **Solução:** Uma defesa leve que requer poucas mudanças no protocolo FL, ajustando o learning rate de agregação por dimensão e por rodada com base nas informações de sinal das atualizações dos agentes. A defesa leva em consideração os passos necessários para realizar um ataque backdoor bem-sucedido.
- **Limitações:**
 - Configurações Não-IID: Defesa pode ter desempenho inferior em não-IID, podendo dificultar a distinção entre atualizações honestas e maliciosas.
 - Sacrifício de Precisão: Leve degradação na precisão geral do modelo
 - Dependência do Parâmetro de Limiar: Eficácia da defesa depende da escolha apropriada do parâmetro de limiar para a learning rate. Configuração inadequada pode levar a um desempenho sub ótimo.

Ozdayi, M. S., Kantarcioglu, M., & Gel, Y. R. (2020). Defending against Backdoors in Federated Learning with Robust Learning Rate (Version 4). arXiv. <https://doi.org/10.48550/ARXIV.2007.03767>

Proposta/ideia de pesquisa



- **Motivação**

- CAVs utilizando FL é um tópico de pesquisa com bastante problemáticas, mesmo considerando apenas sistemas V2V.
- CAVs são o futuro das ruas e precisam estar preparados para eventuais erros e ataques.
- CAVs propiciam um trânsito mais seguro até mesmo para veículos não integrados e não autônomos.


- **Objetivos**

- Criar um sistema robusto para prevenção de ataques de data e model poisoning, sem que o treinamento seja muito prejudicado.
 - Abordar explicabilidade de modelo e treinamento para verificar pontos frágeis suscetíveis a ataques.
 - Abordar self-supervised learning.
 - Possível solução para prevenção de ataques, como label flipping.
 - Melhora no treinamento dos modelos, diminuindo a necessidade de model pruning.
 - Aplicação em adversarial training e feature squeezing.

- **Proposta:**

- Utilizar agregação de técnicas para melhorar a proteção do sistema.
 - Por exemplo: Feature Squeezing e Adversarial Training para detecção de noises em imagens e leitura de sensores. Model Pruning e Anomaly Detection para detecção de ataques nos pesos do gradiente.
 - As verificações e sistemas de segurança devem ser eficientes o suficiente para não perturbar as janelas de agregação e não devem degradar o treinamento.
- Explicabilidade: Entender onde os ataques degradam a rede auxilia na seleção de defesas.
- Self-supervised: Data augmentation de noises para ajudar na prevenção de ataques de label flipping. Além disso, self-supervised diminui o bias no treinamento, diminuindo a necessidade de model pruning e aumentando a confiabilidade da rede.

Cronograma



- 2024
 - Maio - Julho: Revisão bibliográfica. Estudos das técnicas de defesa a ataques em FL.
 - Maio - Julho: Revisão bibliográfica. Estudo das técnicas de defesa a ataques em redes veiculares.
 - Agosto: Estudo da proposta inicial e refinamento do escopo.
 - Agosto: Submeter para a FAPESP.
 - Agosto - Setembro: Explorar ataques em FL e o comportamento de cada técnica de defesa.
 - Agosto - Setembro: Explorar ataques em redes veiculares e o comportamento de cada técnica de defesa.
 - Outubro: Qualificação.
 - Novembro - Dezembro: Estudo das ferramentas de simulação.
- 2025
 - Janeiro - Novembro: Escrita da monografia.
 - Fevereiro - Maio: Construção do protótipo da rede de defesa veicular.
 - Fevereiro - Julho: Estudo de explicabilidade em ML.
 - Agosto - Outubro: Estudo de self-supervised.
 - Maio - Outubro: Validação do sistema de defesa e refinamento do mesmo.
 - Agosto - Outubro: Experimentos com explicabilidade e self-supervised e redirecionamento do sistema para acomodar novas descobertas.
 - Novembro: Defesa da banca.