





Sistema de defesa contra envenenamento em redes de aprendizado federado aplicado a redes veiculares

Yuri Dimitre Dias de Faria


Contextualização do problema




- O que é FL
- O que são sistemas ITSs (Intelligent Transport System)
- O que são CAVs (Connected and Automated Vehicles)
- O que são ataques de envenenamento
- Por que isso é importante?




Contextualização do problema - Data Poisoning




- Objetivo:
 - Destruir ou prejudicar a precisão do modelo global.
 - Direcionar o modelo para cometer erros em determinadas previsões.
- Tipos:
 - Label flipping
 - Poisoning samples
 - Out-of-distribution




Contextualização do problema - Model Poisoning



- **Objetivo:**
 - Manipular diretamente o modelo global para introduzir erros ou vulnerabilidades específicas
 - Causar degradação do modelo persistentemente ou explorar os parâmetros do modelo para fins maliciosos.
- **Tipos:**
 - Random weights generation
 - Optimization methods
 - Information leakage




Contextualização do problema - Problemas em aberto




- **Vulnerabilidade a Ataques de Envenenamento em Aprendizado Federado:** Métodos atuais como FLTrust e Multi-Krum são ineficazes contra métodos sofisticados. Métodos isolados tendem a ser ineficazes.
- **Deteção e Mitigação de Ataques em Ambientes Dinâmicos e Heterogêneos:** Desenvolver métodos de detecção e mitigação de ataques que sejam eficazes em cenários com grande diversidade de dados e clientes
- **Trade-off in defences:** A maioria das defesas, é observado que existe um trade-off entre impedir um certo tipo de ataque e executar a tarefa proposta.

Contextualização do problema - Problemas em aberto



- **Defesa Coordenada entre Servidor e Clientes:**
- **Descrição do Problema:** A defesa contra ataques de envenenamento depende geralmente de técnicas implementadas apenas no servidor ou apenas nos clientes. No entanto, ataques avançados podem explorar vulnerabilidades específicas em um ou outro.
- **Problema em Aberto:** Criar um sistema de defesa coordenada que integre soluções tanto no servidor quanto nos clientes. Um sistema de defesa robusto deve combinar técnicas de agregação robusta, detecção de anomalias, privacidade diferencial e métodos de perturbação para maximizar a segurança em todo o ciclo de aprendizado federado. A questão é como coordenar essas defesas de maneira eficaz, considerando limitações de comunicação, processamento e energia nos dispositivos veiculares.


Trabalhos relacionados



- **Objetivo:** Investigar a resiliência a falhas bizantinas em implementações distribuídas de descida do gradiente estocástico. Como um SGD distribuído pode ter tolerância um número f de processos bizantinos entre n workers.
- **Solução:** Algoritmo de agregação Krum. O Krum seleciona o vetor de atualização que minimiza a soma das distâncias quadradas para seus $n - f$ vetores vizinhos mais próximos.
- **Limitações:**
 - Custo computacional: Complexidade $O(n^2 * d)$, onde d é a dimensão do vetor de parâmetros
 - Desempenho com mini-batch pequeno: Krum pode desacelerar o aprendizado quando o mini-batch for muito pequeno.
 - Condições necessárias para convergência: Precisão do estimador de gradiente.

Peva Blanchard, El Mahdi El Mhamdi, Rachid Guerraoui, and Julien Stainer. 2017. Machine learning with adversaries: byzantine tolerant gradient descent. In Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS'17). Curran Associates Inc., Red Hook, NY, USA, 118–128.


Trabalhos relacionados



- **Objetivo:** Desenvolver defesa contra ataques de envenenamento que já poluíram o global model.
- **Solução:** White Blood Cell for FL. Defesa baseada no cliente que visa identificar o espaço de parâmetros onde reside o efeito de ataque de longa duração e perturbar esse espaço durante o treinamento local.
- **Limitações:**
 - Ataques extremamente fortes: Falha em garantir a robustez quando os ataques são extremamente fortes.
 - Configuração Não-IID: Não-IID pode levar a uma matriz esparsa, que é provável de ter um núcleo de uma dimensão maior, dificultando a mitigação do efeito do ataque.
 - Perda de precisão benigna: Pode resultar em uma queda de 15% de precisão em configurações Não-IID

Sun, J., Li, A., DiValentin, L., Hassanzadeh, A., Chen, Y., & Li, H. (2021). FL-WBC: Enhancing Robustness against Model Poisoning Attacks in Federated Learning from a Client Perspective. In *Advances in Neural Information Processing Systems* (pp. 12613–12624). Curran Associates, Inc..


Trabalhos relacionados



- **Objetivo:** Desenvolver uma defesa contra backdoor em FL usando uma learning rate robusta.
- **Solução:** Uma defesa leve que requer poucas mudanças no protocolo FL, ajustando o learning rate de agregação por dimensão e por rodada com base nas informações de sinal das atualizações dos agentes. A defesa leva em consideração os passos necessários para realizar um ataque backdoor bem-sucedido.
- **Limitações:**
 - Configurações Não-IID: Defesa pode ter desempenho inferior em não-IID, podendo dificultar a distinção entre atualizações honestas e maliciosas.
 - Sacrifício de Precisão: Leve degradação na precisão geral do modelo
 - Dependência do Parâmetro de Limiar: Eficácia da defesa depende da escolha apropriada do parâmetro de limiar para a learning rate. Configuração inadequada pode levar a um desempenho sub ótimo.

Ozdayi, M. S., Kantarcioglu, M., & Gel, Y. R. (2020). Defending against Backdoors in Federated Learning with Robust Learning Rate (Version 4). arXiv. <https://doi.org/10.48550/ARXIV.2007.03767>

Proposta/ideia de pesquisa



- **Motivação**

- Veículos conectados são o futuro das ruas e precisam estar preparados para eventuais erros e ataques.
- Veículos conectados propiciam um trânsito mais seguro até mesmo para veículos não integrados e não autônomos.
- Problema em aberto: Defesa Coordenada entre Servidor e Clientes

- **Objetivos**

- Criar um sistema robusto para prevenção de ataques de data e model poisoning, sem que o treinamento seja muito prejudicado.
 - Dinâmica cliente & servidor.

- **Proposta:**

- Utilizar agregação de técnicas para melhorar a proteção do sistema.
 - Por exemplo: Feature Squeezing e Adversarial Training para detecção de noises em imagens e leitura de sensores. Model Pruning e Anomaly Detection para detecção de ataques nos pesos do gradiente.
 - As verificações e sistemas de segurança devem ser eficientes o suficiente para não perturbar as janelas de agregação e não devem degradar o treinamento.
 - Técnicas devem ser implementadas tanto para proteger o servidor quanto cada cliente.
 - Três pilares:
 - Agregação robusta
 - Identificação de clientes maliciosos, onde o modelo foi envenenado e como tratar esses casos
 - Dados heterogêneos.



- 100% of the respondents were female, and 90% were aged 18 years or older. The majority of the respondents were students (60%), followed by employees (20%), and the remaining 20% were categorized as "other." The majority of the respondents were from the United States (60%), followed by Canada (20%), and the remaining 20% were from other countries.

[illegible]