

Cyberattacks em FL e Contra Medidas

Yuri Dimitre Dias de Faria y218172@dac.unicamp.br

Laboratório de Computação Visual – IMAGELab


May 6, 2024



Table of Contents

1. Introdução
2. Model Poisoning Attacks
3. Data poisoning attacks

4. Data Reconstruction Attacks
5. Defesas, como são feitas e implementações



FACULDADE DE TECNOLOGIA

Table of Contents

1. Introdução
2. Model Poisoning Attacks
3. Data poisoning attacks
4. Data Reconstruction Attacks
5. Defesas, como são feitas e implementações



FACULDADE DE TECNOLOGIA

Tipos de Cyberattacks

- **Data Poisoning:** Modifica o dataset para alcançar um objetivo.
- **Model Poisoning:** Similar à data poisoning, mas ataca o modelo ao invés do dataset. Esse ataque muitas vezes acontece antes da agregação.
- **Data Reconstruction:** São performados tentando inferir informações sensíveis sem interferir no treinamento FL ou dados locais, assumindo que não houve necessariamente um vazamento durante o treinamento local (maquinas perfeitas).

Implementações de ataques

Tipo de ataques	Implementações
	Byzantine attack zero mode, random mod
Model poisoning attacks	Minimizing Distance Backdoor attack
	Model Replacement Backdoor attack
	Lazy Worker (or Free Rider) attack
Data poisoning attacks	Label Flipping backdoor attack
	Edge Case backdoor attack
	Deep Leakage Attack
Data reconstruction attacks	Inverting gradient attack
	Revealing labels attack

Table of Contents

1. Introdução
2. Model Poisoning Attacks
3. Data poisoning attacks


4. Data Reconstruction Attacks
5. Defesas, como são feitas e implementações



FACULDADE DE TECNOLOGIA

Byzantine attacks

- **Zero mode:** Coloca todos os pesos em 0.
- **Random mode:** Manipula o modelo dos clientes atribuindo valores randômicos para o mesmo.
- **Flipping mode:** Manipula o modelo global para a direção oposta por uma formulação de envenenamento local do modelo com base no modelo global w_g e o modelo real w_l como sendo $w_g + (w_g - w_l)$



FACULDADE DE TECNOLOGIA

Minimizing Distance Backdoor Attack

Demonstra que mesmo que atacantes não sendo omniscientes e de pequena escala podem resultar em um backdooring attack de sucesso. Para isso, o atacante vai executar o backdoor otimizado, minimizando as distâncias dos parâmetros originais. Isso é atingido pela função Loss, com peso parametral α que se da:

$$\text{Loss} = \alpha l_{\text{backdoor}} + (1 - \alpha) l_{\Delta}$$

na qual l_{backdoor} é o mesmo que o Loss regular, mas treinado no backdoor de ataque em vez do real, l_{Δ} é o parâmetro para manter os novos parâmetros próximos do original.

Table of Contents

1. Introdução
2. Model Poisoning Attacks
- 3. Data poisoning attacks**

4. Data Reconstruction Attacks
5. Defesas, como são feitas e implementações



FACULDADE DE TECNOLOGIA

Como funcionam

Data poisoning modifica o dataset local, ou de múltiplos clientes, para alcançar um objetivo malicioso, degradando o modelo global. Label Flipping attack, um global “sybil” controla alguns clientes e modifica seus dados locais para classificar erroneamente samples de algumas classes para outras classes.

Como demonstrado em alguns artigos, DPAs podem ser direcionados para alguma classe específica, sem alterar o resultado de outras.

Artigos

- **Data Poisoning Attack Against FL Systems:** Propõem o uso da técnica PCA para identificação de clientes maliciosos. Se identificados nos primeiros rounds, o modelo global não é muito afetado.
- **Physical Backdoor Attacks to Lane Detection Systems in Autonomous Driving:** Backdoor em sistemas autônomos é um grande problema devido a sensores e aprendizado por reforço.

Table of Contents

1. Introdução
2. Model Poisoning Attacks
3. Data poisoning attacks

4. Data Reconstruction Attacks
5. Defesas, como são feitas e implementações



FACULDADE DE TECNOLOGIA

Como funciona

São realizados por adversários passivos tentando inferir informações sensíveis, sem interferir no treinamento ou nos dados locais. Assume-se que não há vazamentos durante o treinamento, i.e., os clientes possuem máquinas completamente confiáveis. DRA pegam o modelo treinado, global ou local, e executa treinamento reverso. Deep Leakage from Gradient (DLG) attack infere dados do treinamento local pelo compartilhamento público de gradientes. Um adversário pode utilizar o round anterior de treinamento FL e o novo obtido pelo modelo para computar um "update de modelo" entre modelos em diferentes rounds de treinamento FL para deduzir os dados.

Deep Leakage Attack

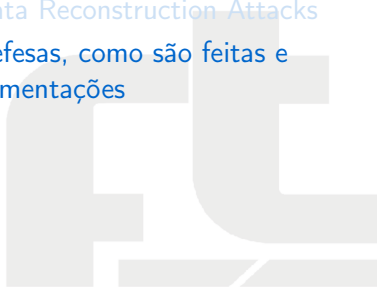
Técnicas sugeridas para evitar o DLG

- **Noisy Gradient:** Adicionar perturbação ao gradiente antes de compartilhar.
- **Gradient Compression And Sparsification:** Gradientes com magnitudes pequenas são podados para zero. Esparsificação maior de 20% resulta no aparecimento de artefatos nas imagens recuperadas. Gradientes podem ser comprimidos 300x sem uma perda significativa na acurácia.
- **Large Batch, High Resolution and Cryptology:** Aumentar o número de parâmetros que o gradiente tenha, e.g., aumentando o tamanho do batch e a resolução da imagem, torna difícil a reconstrução do mesmo. Criptology é a opção mais assertiva, porém tem suas limitações. Secure aggregation requer que o gradiente seja de números inteiros e homomórfica é contra parameter server only.

Table of Contents

1. Introdução
2. Model Poisoning Attacks
3. Data poisoning attacks

4. Data Reconstruction Attacks
5. Defesas, como são feitas e implementações



FACULDADE DE TECNOLOGIA

Before-Aggregation Defenses

Funções B-AD operam em modelos locais no servidor FL, antes da agregação acontecer.

- **Krum** tolera f clientes bizantinos em n clientes apenas retendo um único modelo local que é mais provável que seja benigno para o global. Uma generalização é o m -Krum, que seleciona m modelos de clientes com os m menores scores para a agregação, ao invés de escolher apenas um modelo. Essa abordagem requer que o número de clientes maliciosos seja menor que $\frac{n-m}{2} - 1$.

On-Aggregation Defesas

Funções O-AD modificam a função de agregação para uma versão robusta que tolera ou mitiga os impactos potenciais dos modelos de clientes adversários.

- **Robust Federated Aggregation (RFA)** computa a mediana geométrica do modelo cliente em cada iteração, em vez de apenas calcular a média. A defesa RFA mitiga o impacto de modelos envenenados, já que a mediana geométrica pode representar a tendência central dos modelos clientes, e o ponto mediano é escolhido para minimizar a soma das distâncias entre esse ponto e os demais modelos clientes da iteração FL atual. Na prática, a mediana geométrica é calculada usando o algoritmo Smoothed Weisfeld.

After-Aggregation Defenses

Funções A-AD modificam o resultado da agregação a cada iteração FL para mitigar os efeitos de envenenamento de modelo ou proteger o modelo global de potenciais adversários.

- **CRFL** corta o modelo global para limitar a norma do modelo toda a vez após uma agregação FL. O servidor FL então adiciona um ruído gaussiano ao corte do modelo global antes de distribuir o modelo para os clientes na próxima iteração FL.