

FedPHE: Efficient and Straggler-Resistant Homomorphic Encryption

Framework para Aprendizado Federado Heterogêneo

Yuri Dimitre Dias de Faria


y218172@dac.unicamp.br

Laboratório de Redes de Computadores - LRC


Novembro, 2024



- Aprendizado Federado (FL): Colaboração entre instituições sem compartilhar dados privados.
- Desafios principais:
 - Heterogeneidade dos dados e capacidades computacionais dos clientes.
 - Altos custos computacionais e de comunicação da criptografia homomórfica (HE).
 - Problemas com stragglers (clientes lentos).
- Objetivo: Propor o **FedPHE**, um framework eficiente para FL heterogêneo.




- **FedPHE:** Framework de FL com:
 - Agregação ponderada segura baseada em CKKS (Packed Homomorphic Encryption).
 - Seleção de clientes baseada em esboços (*sketching*).
- Reduz custos de comunicação e melhora a eficiência do treinamento.
- Preserva a privacidade dos dados durante o processo.



FACULDADE DE TECNOLOGIA

- 1 **Treinamento Local:** Clientes treinam modelos locais com SGD.
- 2 **Packed Encryption e Sparsificação:** Modelos locais são empacotados, esparcificados e encriptados.
- 3 **Agregação Encriptada:** O servidor agrega modelos locais encriptados usando CKKS.
- 4 **Seleção de Clientes:** Clientes similares são agrupados, e o mais eficiente de cada cluster é selecionado.



Arquitetura do FedPHE






Fig. 3: A snapshot of FedPHE architecture.




- Necessidade de:
 - **Agregação ponderada** que considera a contribuição de cada cliente.
 - **Eficiência** na comunicação e no cálculo com HE.
 - **Resistência a stragglers** para reduzir atrasos no treinamento.
 - **Seleção de clientes** que preserve privacidade.



FACULDADE DE TECNOLOGIA

- Reduz tráfego de comunicação ao selecionar os parâmetros mais significativos.
- Implementado após o empacotamento e antes da encriptação.
 - Cada cliente começa achatando e empacotando o modelo local
 - Calcula-se um limiar θ para identificar a máscara dada pelo nível de esparsificação $s\%$.
 - A máscara será 1 quando o pacote com valores relevantes forem maiores que o θ , e o pacote é encriptado.
 - O cifrotexto C_i^t , com a máscara correspondente, M_i^t será enviado ao servidor.
- Resultados:
 - Redução no tamanho do cifrotexto sem prejudicar a precisão.



Contribution-aware Weighted Aggregation

- **Foco:** Resolver a heterogeneidade dos dados dos clientes.
- O servidor:
 - Agrega atualizações encriptadas dos clientes selecionados.
 - Utiliza pesos encriptados baseados na contribuição de cada cliente ao modelo global.
- Contribuição do cliente i é quantificada pela similaridade entre os esboços das rodadas $t - 1$ e t :

$$\{h_i^{t-1}, h_i^t\}$$



Contribution-aware Weighted Aggregation

- Similaridade é calculada usando:
 - **Locality-Sensitive Hashing (LSH)**: Aproxima a *Jaccard Similarity*, dada por:

$$JS(X, Y) = \frac{|X \cap Y|}{|X \cup Y|}$$

- O servidor estima a similaridade $JS(w_i^{t-1}, w_i^t)$ com base na probabilidade de colisão.
- Baixa similaridade implica maior inferência, aumentando a agregação dos pesos.
- Cálculo dos pesos agregados:

$$p_i^t = \frac{\exp(-\beta \cdot JS(w_i^{t-1}, w_i^t))}{\sum_{j \in S^t} \exp(-\beta \cdot JS(w_j^{t-1}, w_j^t))}$$

- Onde $\beta > 0$ ajusta a curva exponencial.

Sketching-based Client Selection

Motivação:

- Clientes similares frequentemente enviam dados irrelevantes ou redundantes para o servidor.
- A maioria das técnicas de seleção de clientes utiliza *plaintext*, comprometendo a privacidade.

Metodologia:

- Cada cliente i realiza as seguintes etapas após atualizar seu modelo local w_i^t :
 - ① **Flattening:** Achata w_i^t para um tensor $\overline{w}_i^t$ com d elementos.
 - ② **Geração da Matriz:** Cria uma matriz $\mathcal{M}$ ($k \times d$) com k vetores de dimensão d usando uma *seed* compartilhada s .
 - ③ **Sketching:** Utiliza **Locally Sensitive Hashing (LSH)** para reduzir dimensionalmente $\overline{w}_i^t$ e gerar um *sketch* h_i^t .
- O *sketch* h_i^t é enviado ao servidor, que:
 - Agrupa clientes similares.
 - Seleciona o cliente mais rápido de cada grupo.

Locally Sensitive Hashing (LSH):

- LSH é uma família de funções $\mathcal{H} : \mathbb{R}^d \rightarrow \mathbb{S}$ que preserva a similaridade:
- **Propriedade:** Duas entradas são similares no espaço de dados original, então eles terão alta similaridade depois de serem convertidas pelo hash.
- Estima a *Jaccard Similarity* entre atualizações w_i^{t-1} e w_i^t :

$$Pr_h(h_i^{t-1} = h_i^t) = JS(w_i^{t-1}, w_i^t) = \frac{|w_i^{t-1} \cap w_i^t|}{|w_i^{t-1} \cup w_i^t|}$$

- Propriedades:
 - Se $d(w_p, w_q) < R$: $Pr_{\zeta}(h(w_p) = h(w_q)) \geq p_1$
 - Se $d(w_p, w_q) \geq cR$: $Pr_{\zeta}(h(w_p) = h(w_q)) \leq p_2$
 - Onde R é um limiar e c é um fator de aproximação.

Privacidade:

- O *sketch* h_i^t é uma representação condensada que não contém dados sensíveis, garantindo a privacidade do cliente.

Etapas de Clusterização:

- Após receber as atualizações locais (*sketches* h_i^t), o servidor realiza a clusterização para agrupar clientes similares.
- O número de clusters C é calculado como:

$$C = \min(\mathbb{G}(\{h_1^t, \dots, h_N^t\}), \gamma N)$$

- $\mathbb{G}(\cdot)$: **Gap Statistic**, um método padrão para determinar o número ótimo de clusters.
- γ : Limiar máximo para o número de clusters, ajustando o limite superior.

Gap Statistic:

- Compara a variação intra-cluster com valores esperados baseados em uma distribuição nula gerada por simulação Monte Carlo.
- Fórmula do *gap statistic* para k clusters:

$$\mathbb{G}_n(k) = \mathbb{E}_n^*(\log W_k) - \log W_k$$

Critério de Seleção:

- O servidor prioriza clientes com maior capacidade de treinamento (rapidez e engajamento histórico).
- Define-se T_i^t como a ordem de chegada da atualização local do cliente i ao servidor na rodada t .
- A prioridade de seleção $\mathbb{F}_i^t$ é calculada como:

$$\mathbb{F}_i^t = \frac{1}{\alpha \delta_i^{t-1} + (1 - \alpha) \times T_i^t}$$

Objetivo:

- Selecionar clientes com maior prioridade ($\mathbb{F}_i^t$).
- Combinar desempenho histórico (δ_i^{t-1}) e eficiência atual (T_i^t).

Definições dos Parâmetros:

- $\alpha \in (0, 1)$: Fator de influência que ajusta o peso entre histórico e rodada atual.
- δ_i^{t-1} : Média histórica do engajamento do cliente i até a rodada $t - 1$:

$$\delta_i^{t-1} = \frac{1}{t} \sum_{j=0}^t T_i^j$$

- T_i^t : Tempo de resposta (ou ordem de chegada) do cliente i na rodada atual t .

Interpretação:

- Clientes mais rápidos (T_i^t baixo) têm maior prioridade.
- O histórico (δ_i^{t-1}) penaliza clientes com desempenho inconsistente ao longo das rodadas.
- A combinação de α e os dois termos otimiza a seleção, equilibrando histórico e eficiência atual.

- Servidor não conspira com clientes
- Servidor e clientes são admitidos como honestos-mas-curiosos.
- Numero de clientes: 8
- Dirichlet factor: $\alpha = 1$
- CKKS e BFV
 - Grau do módulo do polinômio: 8192
- Clientes retardatários (stragglers): 25%
 - Delay de 2 - 5 rodadas
- Batch size: 64
- Learning rate : $1e - 1$
- Funções de hash LSH: 200
- Rodadas:100




FACULDADE DE TECNOLOGIA


- Mnist, FashionMnist e CIFAR-10
- Mnist e FashionMnist: 60k/10k treino/teste
- CIFAR-10: 50k/10k treino/teste
- Modelos:
 - LeNet-5 : Mnist
 - CNN model with 2 convolutional layers and 1 FC: FashionMnist
 - ResNet-20: CIFAR-10
- Comparações: Plain-text, Batchcrypt, PackadBFV, PackedCKKS, FedAVG, FLANP.




Resultados Experimentais



(a) MNIST



(b) FashionMNIST



(c) CIFAR-10

Fig. 6: Accuracy versus global rounds of FedPHE and the baselines on different datasets.




TABLE III: Network traffic, accuracy, and training time in 100 rounds of FedPHE and the baselines on different datasets.


Dataset	Metric	Plaintext	BatchCrypt	PackedBFV	PackedCKKS	FedPHE
MNIST	Traffic (MB)	81	217	3959	2886	175
	Accuracy	95.94%	95.50%	95.10%	95.44%	95.04%
	Time (s)	342.34	1377.03	652.78	885.90	743.26
FashionMNIST	Traffic (MB)	73	196	3300	2550	151
	Accuracy	89.22%	89.42%	89.10%	89.07%	88.96%
	Time (s)	333.15	1590.23	650.68	823.88	690.65
CIFAR-10	Traffic (MB)	523	1256	22107	17089	5165
	Accuracy	72.95%	73.79%	71.02%	74.77%	71.37%
	Time (s)	1016.62	7126.14	1491.74	2419.18	1605.71



FACULDADE DE TECNOLOGIA



(a) Number of Clusters



(b) Number of Selected Clients

Fig. 8: Number of clusters in each iteration and number of selected clients of FedPHE and the baselines.

- Aceleração do treinamento: $1.85\times$ a $4.44\times$.
- Redução de tráfego de comunicação: até $22.62\times$.
- Precisão similar (diferença $< 1.58\%$).



FACULDADE DE TECNOLOGIA

- O FedPHE combina eficiência, privacidade e robustez para aprendizado federado em cenários heterogêneos.
- Reduz custos de comunicação e acelera o treinamento sem sacrificar precisão.
- Mostra-se aplicável a cenários reais.



FACULDADE DE TECNOLOGIA